强化学习原理：
——TRPO&PPO

杨博渊

yby@nankai.edu.cn

2023.04.28

策略梯度的缺点

1. 很难在整个优化过程选择一个时间步长，特别是由于状态和回报在改变统计特性。

2. 策略经常会过早地收敛到一个次优的几乎确定的策略。

步长的重要性！

当步长不合适时，所学到的策略是一个坏的策略，由坏的策略所采集到的数据也是不好的数据，学习很可能会崩溃

替代回报函数

用 τ 表示一组状态-行为序列$s_0, u_0, \cdots, s_H, u_H$

目标函数为：

$$\eta(\tilde{\pi}) = E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t))\right]$$

等价的替代函数

$$\eta(\tilde{\pi}) = \eta(\pi) + E_{s_0, a_0, \cdots \sim\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t A_\pi(s_t, a_t)\right]$$

老的策略

新旧策略回报差

优势函数的定义：

$$A_\pi(s,a) = Q_\pi(s,a) - V_\pi(s)$$
$$= E_{s'\sim P(s'|s,a)}[r(s) + \gamma V^\pi(s') - V^\pi(s)]$$

证明：

$$E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t A_\pi(s_t,a_t)\right]$$

$$= E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s) + \gamma V^\pi(s_{t+1}) - V^\pi(s_t))\right]$$

$$= E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t)) + \sum_{t=0}^{\infty}\gamma^t(\gamma V^\pi(s_{t+1}) - V^\pi(s_t))\right]$$

$$= E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t))\right] + E_{s_0}[-V^\pi(s_0)]$$

$$= \eta(\tilde{\pi}) - \eta(\pi)$$

替代回报函数

用 τ 表示一组状态-行为序列$s_0, u_0, \cdots, s_H, u_H$

目标函数为：

$$\eta(\tilde{\pi}) = E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t))\right]$$

等价的替代函数

$$\eta(\tilde{\pi}) = \eta(\pi) + E_{s_0, a_0, \cdots \sim \tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t A_\pi(s_t, a_t)\right]$$

老的策略

新旧策略回报差

定义：

$$\rho_\pi(s) = P(s_0 = s) + \gamma P(s_1 = s) + \gamma^2 P(s_2 = s) + \cdots$$

第t步出现s的概率

状态s处动作进行加和

$$\eta(\tilde{\pi}) = \eta(\pi) + \sum_{t=0}^{\infty}\sum_{s} P(s_t = s|\tilde{\pi}) \sum_{a}\tilde{\pi}(a|s)\gamma^t A_\pi(s, a)$$

$$= \eta(\pi) + \sum_{s}\rho_{\tilde{\pi}}(s)\sum_{a}\tilde{\pi}(a|s)A^\pi(s, a)$$

替代回报函数

用 τ 表示一组状态-行为序列$s_0, u_0, \cdots, s_H, u_H$

目标函数为：

$$\eta(\tilde{\pi}) = E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t))\right]$$

等价的替代函数

$$\eta(\tilde{\pi}) = \eta(\pi) + E_{s_0,a_0,\cdots\sim\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t A_\pi(s_t,a_t)\right]$$

老的策略

新旧策略回报差

$$= \eta(\pi) + \sum_s \rho_{\tilde{\pi}}(s)\sum_a \tilde{\pi}(a|s)A^\pi(s,a)$$

策略改善理论

$$v_\pi(s) \leqslant q_\pi(s,\pi'(s))$$

$$= \mathbb{E}[R_{t+1} + \gamma v_\pi(s_{t+1})|s_t = s,\ a_t = \pi'(s)]$$

$$= \mathbb{E}_{\pi'}[R_{t+1} + \gamma v_\pi(s_{t+1})|s_t = s]$$

$$\leqslant \mathbb{E}_{\pi'}[R_{t+1} + \gamma q_\pi(s_{t+1},\pi'(s_{t+1}))|s_t = s]$$

$$= \mathbb{E}_{\pi'}[R_{t+1} + \gamma\mathbb{E}_{\pi'}[R_{t+2} + \gamma v_\pi(s_{t+1})|s_{t+1},a_{t+1} = \pi'(s_{t+1})]|s_t = s]$$

$$= \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 v_\pi(s_{t+2})|s_t = s]$$

$$\leqslant \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 v_\pi(s_{t+2})|s_t = s]$$

$$\vdots$$

$$\leqslant \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 R_{t+4} + \cdots|s_t = s]$$

$$= v_{\pi'}(s)$$

替代回报函数

用 τ 表示一组状态-行为序列$s_0, u_0, \cdots, s_H, u_H$

目标函数为：

$$\eta(\tilde{\pi}) = E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t))\right]$$

等价的替代函数

$$\eta(\tilde{\pi}) = \eta(\pi) + E_{s_0, a_0, \cdots \sim \tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t A_\pi(s_t, a_t)\right]$$

老的策略

新旧策略回报差

$$= \eta(\pi) + \sum_s \rho_{\tilde{\pi}}(s)\sum_a \tilde{\pi}(a|s)A^\pi(s,a)$$

策略改善理论

一个更好的策略应该满足：

在每个状态s处：

$$\sum_a \tilde{\pi}(a\,|\,s)A^\pi(s,a) \geq 0$$

然而，在函数逼近的情况下：

存在估计和逼近误差，因此导致在一些状态处

$$\sum_a \tilde{\pi}(a\,|\,s)A^\pi(s,a) < 0$$

替代回报函数

用 τ 表示一组状态-行为序列$s_0, u_0, \cdots, s_H, u_H$

目标函数为：

$$\eta(\tilde{\pi}) = E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t))\right]$$

等价的替代函数

$$\eta(\tilde{\pi}) = \eta(\pi) + E_{s_0,a_0,\cdots\sim\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t A_\pi(s_t,a_t)\right]$$

老的策略

新旧策略回报差

$$\eta(\tilde{\pi}) = \eta(\pi) + \sum_s \rho_{\tilde{\pi}}(s)\sum_a \tilde{\pi}(a|s)A^\pi(s,a)$$

注意：这时状态分布由新的策略产生，对新的策略严重依赖

第一个技巧：对状态分布的处理，忽略状态分布的变化，依然用旧的策略所对应的状态分布

$$L_\pi(\tilde{\pi}) = \eta(\pi) + \sum_s \rho_\pi(s)\sum_a \tilde{\pi}(a|s)A^\pi(s,a)$$

第二个技巧：对动作分布的处理，重要性采样

$$\sum_a \tilde{\pi}_\theta(a|s_n)A_{\theta_{old}}(s_n,a) = E_{a\sim q}\left[\frac{\tilde{\pi}_\theta(a|s_n)}{q(a|s_n)}A_{\theta_{old}}(s_n,a)\right]$$

替代回报函数

用 τ 表示一组状态-行为序列$s_0, u_0, \cdots, s_H, u_H$

目标函数为：

$$\eta(\tilde{\pi}) = E_{\tau|\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t(r(s_t))\right]$$

等价的替代函数

$$\eta(\tilde{\pi}) = \eta(\pi) + E_{s_0, a_0, \cdots \sim\tilde{\pi}}\left[\sum_{t=0}^{\infty}\gamma^t A_\pi(s_t, a_t)\right]$$

老的策略

新旧策略回报差

$$L_\pi(\tilde{\pi}) = \eta(\pi) + \sum_s \rho_\pi(s)\sum_a \tilde{\pi}(a|s)A^\pi(s,a)$$

$$\sum_a \tilde{\pi}_\theta(a|s_n)A_{\theta_{old}}(s_n,a) = E_{a\sim q}\left[\frac{\tilde{\pi}_\theta(a|s_n)}{q(a|s_n)}A_{\theta_{old}}(s_n,a)\right]$$

$\frac{1}{1-\gamma}E_{s\sim\rho_{\theta_{old}}}[\cdots]$ 代替 $\sum_s \rho_{\theta_{old}}(s)[\cdots]$

$$q(a|s_n) = \pi_{\theta_{old}}(a|s_n)$$

$$L_\pi(\tilde{\pi}) = \eta(\pi) + E_{s\sim\rho_{\theta_{old}}, a\sim\pi_{\theta_{old}}}\left[\frac{\tilde{\pi}_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}A_{\theta_{old}}(s,a)\right]$$

原回报函数与替代回报函数比较

原回报函数：

$$\eta(\tilde{\pi}) = \eta(\pi) + \sum_s \rho_{\tilde{\pi}}(s) \sum_a \tilde{\pi}(a|s) A^{\pi}(s,a)$$

替代回报函数：

$$L_{\pi_{\theta_{old}}}(\pi_\theta) = \eta(\pi_{\theta_{old}}) + E_{s\sim\rho_{\theta_{old}}, a\sim\pi_{\theta_{old}}}[\frac{\tilde{\pi}_\theta(a|s)}{\pi_{\theta_{old}}(a|s)} A_{\theta_{old}}(s,a)]$$

在 θ_{old} 处一阶近似：

$$L_{\pi_{\theta_{old}}}(\pi_{\theta_{old}}) = \eta(\pi_{\theta_{old}})$$

$$\nabla_\theta L_{\pi_{\theta_{old}}}(\pi_\theta)|_{\theta=\theta_{old}} = \nabla_\theta \eta(\pi_\theta)|_{\theta=\theta_{old}}$$

在 θ_{old} 附近，能改善L的策略也能改善原回报函数。问题是步长多大呢？

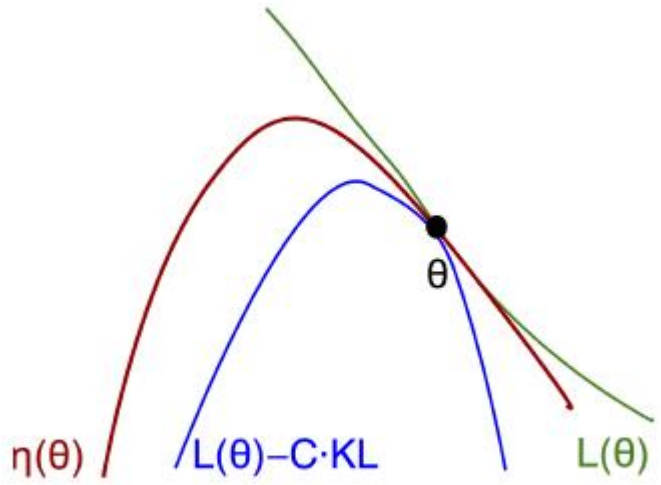

原回报函数与替代回报函数比较

定理1：

令 $\alpha=\mathrm{D}_{TV}^{\max}(\pi_{old},\pi_{new})$ ，则存在下面的界：

$$\eta(\pi_{new})\geq L_{\pi_{old}}(\pi_{new})-\frac{4\varepsilon}{(1-\gamma)^2}\alpha^2$$

Where: $\varepsilon=\max_{s,a}\left|A_{\pi}(s,a)\right|$

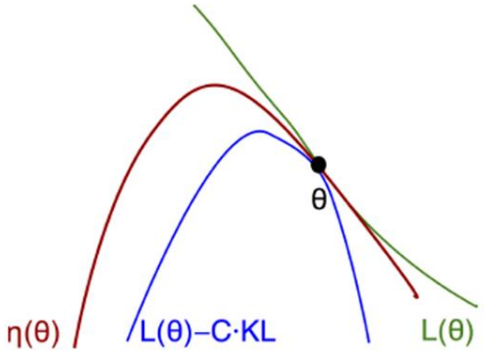

Algorithm 1 Policy iteration algorithm guaranteeing non-decreasing expected return η

Initialize π_0.

for $i=0,1,2,\ldots$ until convergence **do**

Compute all advantage values $A_{\pi_i}(s,a)$.

Solve the constrained optimization problem

$$\pi_{i+1}=\arg\max_{\pi}\left[L_{\pi_i}(\pi)-CD_{\mathrm{KL}}^{\max}(\pi_i,\pi)\right]$$

where $C=4\epsilon\gamma/(1-\gamma)^2$

and $L_{\pi_i}(\pi)=\eta(\pi_i)+\sum_s\rho_{\pi_i}(s)\sum_a\pi(a|s)A_{\pi_i}(s,a)$

end for

策略迭代算法

单调改进策略

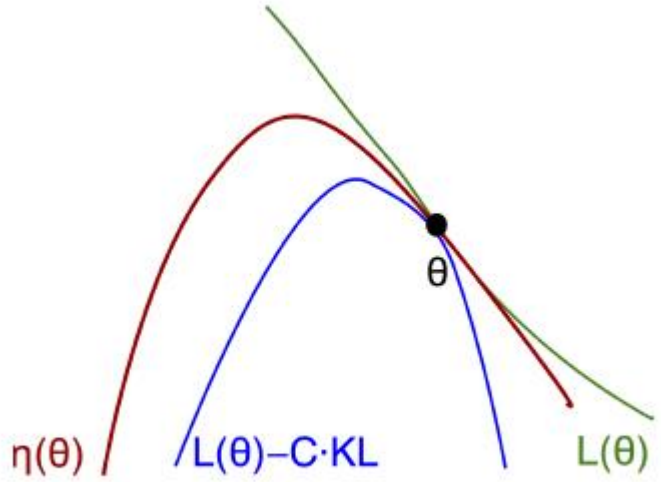

$$\eta(\tilde{\pi}) \geqslant L_{\pi}(\tilde{\pi}) - CD_{KL}^{\max}(\pi, \tilde{\pi}),$$

$$where\ C = \frac{2\varepsilon\gamma}{(1-\gamma)^2}$$

令： $M_i(\pi) = L_{\pi_i}(\pi) - CD_{KL}^{\max}(\pi_i, \pi)$

则： $\eta(\pi_{i+1}) \geqslant M_i(\pi_{i+1})$

又因为： $\eta(\pi_i) = M_i(\pi_i)$

所以： $\eta(\pi_{i+1}) - \eta(\pi_i) \geqslant M_i(\pi_{i+1}) - M(\pi_i)$

所以每次最大化 M_i 能够保证策略非递减。

如何利用理论来得到最优的策略 π_{i+1}？

参数化策略！

TRPO实用算法：优化参数化的策略

问题形式化为：

$$\underset{\theta}{\text{maximize}}\left[L_{\theta_{old}}(\theta)-CD_{KL}^{\max}(\theta_{old},\theta)\right]$$

如果利用惩罚因子C则每次迭代步长很小，
因此问题可转化为：

$$\underset{\theta}{\text{maximize}}\,E_{s\sim\rho_{\theta_{old}},a\sim\pi_{\theta_{old}}}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}A_{\theta_{old}}(s,a)\right]$$

$$subject\ to\quad D_{KL}^{\max}(\theta_{old},\theta)\leqslant\delta$$

无穷多个状态，无穷多约束

第三个技巧：利用平均KL散度：

$$subject\ to\ \bar{D}_{KL}^{\rho_{\theta_{old}}}(\theta_{old},\theta)\leqslant\delta$$

第四个技巧：利用当前策略状态空间分布

$$s\sim\rho_{\theta_{old}}\rightarrow s\sim\pi_{\theta_{old}}$$

TRPO的问题形式化为：

$$\underset{\theta}{\text{maximize}}\,E_{s\sim\pi_{\theta_{old}},a\sim\pi_{\theta_{old}}}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}A_{\theta_{old}}(s,a)\right]$$

$$subject\ to\ E_{s\sim\pi_{\theta_{old}}}\left[D_{KL}(\pi_{\theta_{old}}(\cdot|s)||\pi_\theta(\cdot|s))\right]\leqslant\delta$$

TRPO实用算法

第三个技巧：利用平均KL散度：

$$subject\ to\ \bar{D}_{KL}^{\rho_{\theta_{old}}}(\theta_{old},\theta) \leqslant \delta$$

第四个技巧：利用当前策略状态空间分布

$$s\sim\rho_{\theta_{old}} \rightarrow s\sim\pi_{\theta_{old}}$$

TRPO的问题形式化为：

$$\max_{\theta} imize\, E_{s\sim\pi_{\theta_{old}},a\sim\pi_{\theta_{old}}}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}A_{\theta_{old}}(s,a)\right]$$

$$subject\ to\ E_{s\sim\pi_{\theta_{old}}}\left[D_{KL}(\pi_{\theta_{old}}(\cdot|s)||\pi_\theta(\cdot|s))\right] \leqslant \delta$$

如何得到目标函数和约束条件？

基于采样的方法对目标函数和约束进行估计

利用蒙特卡洛方法估计：

利用样本的平均值来代替期望

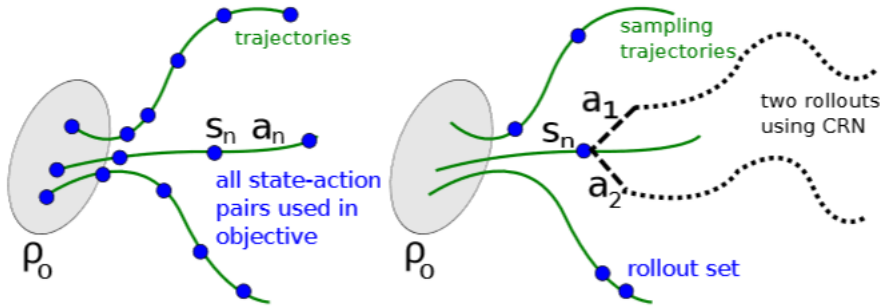

Single path　　Vine

TRPO实用算法

第三个技巧：利用平均KL散度：

$$subject\ to\ \bar{D}_{KL}^{\rho_{\theta_{old}}}(\theta_{old},\theta) \leqslant \delta$$

第四个技巧：利用当前策略状态空间分布

$$s\sim\rho_{\theta_{old}} \rightarrow s\sim\pi_{\theta_{old}}$$

TRPO的问题形式化为：

$$\max_{\theta} imize\, E_{s\sim\pi_{\theta_{old}},a\sim\pi_{\theta_{old}}}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}A_{\theta_{old}}(s,a)\right]$$

$$subject\ to\ E_{s\sim\pi_{\theta_{old}}}\left[D_{KL}(\pi_{\theta_{old}}(\cdot|s)||\pi_\theta(\cdot|s))\right] \leqslant \delta$$

TRPO算法流程：

For 迭代 1,2，… do

运行当前策略T步或N条轨迹

利用所有时间步数据估计优势函数

利用共轭梯度法和线性搜索计算参数更新

End for

共轭梯度法搜索可行方向

$$\underset{\theta}{maximize}\, E_{s\sim\pi_{\theta_{old}},a\sim\pi_{\theta_{old}}}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}A_{\theta_{old}}(s,a)\right]$$

$$subject\ to\ E_{s\sim\pi_{\theta_{old}}}\left[D_{KL}(\pi_{\theta_{old}}(\cdot|s)||\pi_\theta(\cdot|s))\right]\leqslant\delta$$

将目标进行线性化逼近，将约束进行二次逼近后优化问题为：

$$\underset{\theta}{maximize}\ \left[\nabla_\theta L_{\theta_{old}}(\theta)\big|_{\theta=\theta_{old}}\cdot(\theta-\theta_{old})\right]$$

$$subject\ to\ \frac{1}{2}(\theta_{old}-\theta)^T A(\theta_{old})(\theta_{old}-\theta)\leqslant\delta$$

A为Fisher信息矩阵：

$$A_{ij}=\frac{\partial}{\partial\theta_i}\frac{\partial}{\partial\theta_j}\bar{D}_{KL}(\theta_{old},\theta)$$

$$\underbrace{\frac{\partial\mu_a(x)}{\partial\theta_i}\,kl''_{ab}(\mu_\theta(x),\mu_{old}(x))\frac{\partial\mu_b(x)}{\partial\theta_j}}_{J^TMJ}+\underbrace{\frac{\partial^2\mu_a(x)}{\partial\theta_i\partial\theta_j}\,kl'_a(\mu_\theta(x),\mu_{old}(x))}_{=0\ at\ \mu_\theta=\mu_{old}}$$

共轭梯度法搜索可行方向

$$\max_{\theta} imize\, E_{s\sim\pi_{\theta_{old}},a\sim\pi_{\theta_{old}}}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)}A_{\theta_{old}}(s,a)\right]$$

$$subject\ to\ E_{s\sim\pi_{\theta_{old}}}\left[D_{KL}(\pi_{\theta_{old}}(\cdot|s)||\pi_\theta(\cdot|s))\right]\leqslant\delta$$

将目标进行线性化逼近，将约束进行二次逼近后优化问题为：

$$\max_{\theta} imize\ \left[\nabla_\theta L_{\theta_{old}}(\theta)\big|_{\theta=\theta_{old}}\cdot(\theta-\theta_{old})\right]$$

$$subject\ to\ \frac{1}{2}(\theta_{old}-\theta)^T A(\theta_{old})(\theta_{old}-\theta)\leqslant\delta$$

令 $d=\theta-\theta_{old}$ 为搜索方向，则搜索方向应该满足： $A(\theta_{old})d=\nabla_\theta L_{\theta_{old}}(\theta)\big|_{\theta=\theta_{old}}$

利用共轭梯度方法求解线性方程组 $AX=b$ 的解方法：

构造目标函数 $f(x)=\frac{1}{2}x^TAx-bx$，则 x 是目标函数的最小值。

Step1: 给定初试迭代点 $x^{(1)}$，令 $k=1$

Step2:计算梯度 $g_k=\nabla f(x^{(k)})=Ax^{(k)}-b$，若 $\|g_k\|=0$ 则停止计算，并令 $x^*=x^{(k)}$，否则转下一步

Step3：构造搜索方向，首先计算步长 $\beta_{k-1}=\frac{(d^{(k-1)})^TAg_k}{(d^{(k-1)})^TAd^{(k)}}$，若 $k=1,\beta_{k-1}=0$

搜索方向为： $d^k=-g_k+\beta_{k-1}d^{k-1}$

Step4: 计算搜索步长 $\lambda_k=-\frac{g_k^Td^{(k)}}{(d^{(k)})^TAd^{(k)}}$，更新数据点 $x^{(k+1)}=x^{(k)}+\lambda_kd^{(k)}$

Step5：若 $k=n$，则停止计算。得到 $x^*=x^{(k+1)}$，否则令 $k=k+1$，转步骤 step2

此处： $b=\nabla_\theta L_{\theta_{old}}(\theta)\big|_{\theta=\theta_{old}}$

线性搜索得到步长

第二步，利用线性搜索方法计算步长β：

将第一步求得的搜索方向d乘以步长，带入约束方程得到：

$$\delta \approx \frac{1}{2}(\beta d)^T A(\beta d) = \frac{1}{2}\beta^2 d^T A d$$

从而得到步长为：$\beta = \sqrt{\frac{2\delta}{d^T A d}}$

将β带入目标函数$L_{\theta_{old}}(\theta) - \mathcal{X}\left[\bar{D}_{KL}(\theta_{old},\theta) \leqslant \delta\right]$，其中$\mathcal{X}\left[\bar{D}_{KL}(\theta_{old},\theta) \leqslant \delta\right]$表示当满足不等式时为 零，当不满足不等式时为无穷大。收缩步长β，直到目标函数得到改善。

$$\theta_{new} = \theta_{old} + \beta d$$

近端策略优化算法（PPO）

策略梯度的目标函数：

$$L^{PG}(\theta) = E_t\left[\log \pi_\theta(a_t \mid s_t)\hat{A}_t\right]$$

TRPO目标函数：

$$\underset{\theta}{\text{maximize}}\, E_{s\sim\pi_{\theta_{old}},\, a\sim\pi_{\theta_{old}}}\left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{old}}(a|s)} A_{\theta_{old}}(s,a)\right]$$

$$subject\ to\ E_{s\sim\pi_{\theta_{old}}}\left[D_{KL}\left(\pi_{\theta_{old}}(\cdot|s)\,||\,\pi_\theta(\cdot|s)\right)\right] \leqslant \delta$$

CLIP目标函数：

$$L^{CLIP}(\theta) = E_t[\min(r_t(\theta)\hat{A}_t, clip(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t)]$$

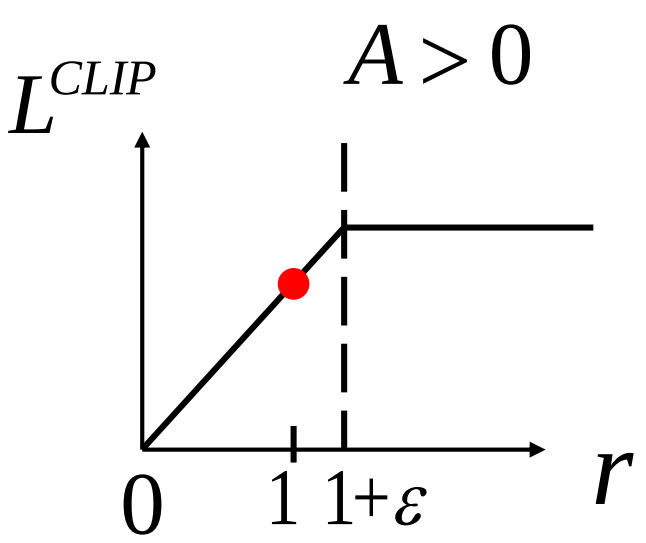

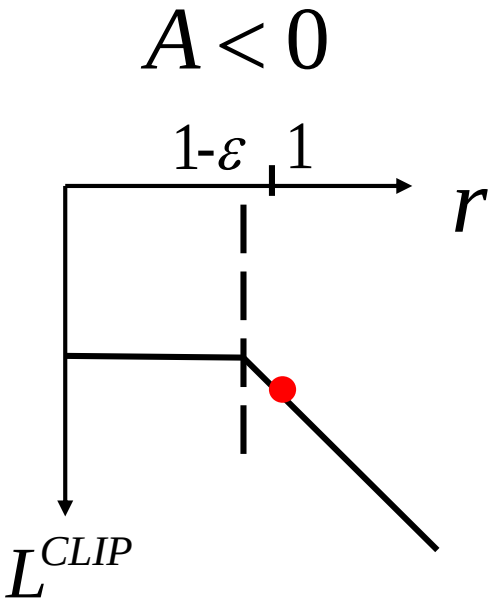

优化更低的界

近端策略优化算法（PPO）

PPO目标函数：

$$L_t^{CLIP+VF+S}(\theta)=\hat{E}_t[L_t^{CLIP}(\theta)-c_1L_t^{VF}(\theta)+c_2S[\pi_\theta](s_t)]$$

其中：V_t^{VF} 为值函数损失函数，S为熵。

为减小方差，优势函数可写为：

$$\hat{A}_t=\delta_t+(\gamma\lambda)\delta_{t+1}+\cdots+(\gamma\lambda)^{T-t+1}\delta_{T-1}$$

其中：$\delta_t=r_t+\gamma V(s_{t+1})-V(s_t)$

近端策略优化算法（PPO）

Algorithm 1 PPO, Actor-Critic Style

for iteration=$1, 2, \ldots$ **do**
  for actor=$1, 2, \ldots, N$ **do**
    Run policy $\pi_{\theta_{\text{old}}}$ in environment for T timesteps
    Compute advantage estimates $\hat{A}_1, \ldots, \hat{A}_T$
  end for
  Optimize surrogate L wrt θ, with K epochs and minibatch size $M \leq NT$
  $\theta_{\text{old}} \leftarrow \theta$
end for

PPO伪代码

TRPO用到的信息论

熵的概念：熵是信息多少的度量

离散系统： $H(X) = -\sum_i p_i \log p_i$

连续系统： $H(x) = E_{x\sim P}[I(x)] = -E_{x\sim P}[\log P(x)]$

熵是不确定性的度量：不确定度越大，熵越大

二值熵定义：

$$H = -p\log(p) - (1-p)\log(1-p)$$

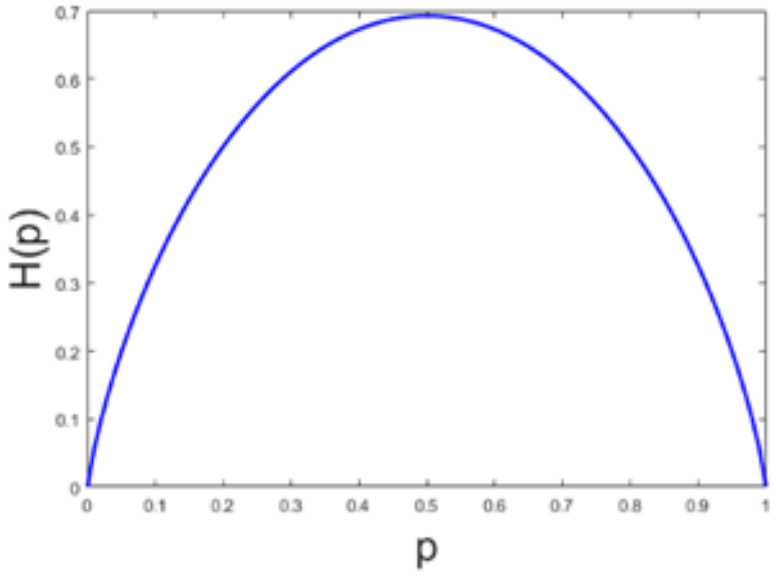

TRPO用到的信息论

交叉熵：

$$H(P,\ Q) = -E_{P(x)}Q(x) = -\int P(x)\log Q(x)dx$$

交叉熵用来衡量编码方案不一定完美时，平均编码的长度

KL散度：衡量两个概率分布之间的距离

$$D_{KL}(P||Q) = E_{x\sim P}\left[\log\frac{P(x)}{Q(x)}\right] = \int P(x)\log P(x)dx - \int P(x)\log Q(x)dx$$

作业

1. 阅读 Trust Region Policy Optimization 和 Proximal Policy Optimization Algorithms